

# Capítulo 5 Distribuciones de probabilidad multivariantes

## 5.1 Introducción

La intersección de dos o más eventos es frecuentemente de interés para un experimentador. Suponga que  $Y_1, Y_2, \dots, Y_n$  denota los resultados de  $n$  intentos sucesivos de un experimento. Un conjunto específico de resultados o mediciones muestrales puede ser expresado en términos de la intersección de los  $n$  eventos ( $Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n$ ), que denotaremos como ( $Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n$ ), que denotaremos como ( $Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n$ ) o bien como  $(y_1, y_2, \dots, y_n)$ . El cálculo de la probabilidad de esta intersección es esencial para hacer inferencias de la población de la cual se toma.

## 5.2 Distribuciones de probabilidad bivalentes y multivariantes

Se pueden definir muchas variables aleatorias sobre el mismo espacio muestral. Por ejemplo al tirar un par de dados el espacio muestral es de 36 puntos. Que corresponden a los valores posibles de ambos dados. Se puede decir que los valores que cada dado puede tomar es una variable aleatoria entonces al tirar ambos se estará buscando la probabilidad conjunta de dos variables aleatorias.

### Definición 5.1

Sean  $Y_1$  y  $Y_2$  variables aleatorias discretas. La *función de probabilidad conjunta* (o bivalente) para  $Y_1$  y  $Y_2$  está dada por

$$p(y_1, y_2) = P(Y_1 = y_1, Y_2 = y_2)$$

cuando  $-\infty < y_1 < \infty, -\infty < y_2 < \infty$ .

### Teorema 5.1

Si  $Y_1$  y  $Y_2$  son variables aleatorias discretas con función de probabilidad conjunta  $p(y_1, y_2)$ , entonces

1.  $p(y_1, y_2) \geq 0$  para toda  $y_1, y_2$ .
2.  $\sum_{y_1, y_2} p(y_1, y_2) = 1$ , donde la suma es para todos los valores  $(y_1, y_2)$  a los que se asignan probabilidades diferentes de cero.

Al igual que en el caso univariado, la función de probabilidad conjunta para variables aleatorias discretas a veces se denomina *función de masa de probabilidad conjunta*. De la misma manera la distinción entre variables aleatorias continuas conjuntas y discretas conjuntas puede ser caracterizado en términos de sus funciones de distribución.

### Definición 5.2

Para cualesquiera variables aleatorias  $Y_1$  y  $Y_2$ , la función de distribución (bivalente) conjunta  $F(y_1, y_2)$  es

$$F(y_1, y_2) = P(Y_1 \leq y_1, Y_2 \leq y_2)$$

cuando  $-\infty < y_1 < \infty, -\infty < y_2 < \infty$

Para dos variables discretas  $Y_1$  y  $Y_2$ ,  $F(y_1, y_2)$  está dada por

$$F(y_1, y_2) = \sum_{t_1 \leq y_1} \sum_{t_2 \leq y_2} p(t_1, t_2)$$

Se dice que dos variables aleatorias son continuas conjuntas si su función de distribución conjunta  $F(y_1, y_2)$  es continua en ambos segmentos.

### Definición 5.3

Sean  $Y_1$  y  $Y_2$  variables aleatorias continuas con función de distribución conjunta  $F(y_1, y_2)$ . Si existe una función no negativa  $f(y_1, y_2)$ , tal que

$$F(y_1, y_2) = \int_{-\infty}^{y_1} \int_{-\infty}^{y_2} f(t_1, t_2) dt_1 dt_2$$

Para toda  $-\infty < y_1 < \infty, -\infty < y_2 < \infty$ , entonces se dice que  $Y_1$  y  $Y_2$  son *variables aleatorias continuas conjuntas*. La función  $f(y_1, y_2)$  recibe el nombre de *función de densidad de probabilidad conjunta*.

De la misma manera que en el caso univariado, las funciones de distribución acumulativas satisfacen ciertas propiedades las cuales se muestran en el siguiente teorema.

### Teorema 5.2

Si  $Y_1$  y  $Y_2$  son variables aleatorias con función de distribución conjunta  $F(y_1, y_2)$ , entonces

1.  $F(-\infty, \infty) = F(-\infty, y_2) = F(y_1, -\infty) = 0$ .
2.  $F(\infty, \infty) = 1$ .
3. Si  $y_1^* \geq y_1$  y  $y_2^* \geq y_2$ , entonces


$$F(y_1^*, y_2^*) - F(y_1^*, y_2) - F(y_1, y_2^*) + F(y_1, y_2) \geq 0$$

### Teorema 5.3

Si  $Y_1$  y  $Y_2$  son variables aleatorias continuas conjuntas con una función de densidad conjunta dada por  $f(y_1, y_2)$ , entonces

1.  $f(y_1, y_2) \geq 0$  para toda  $y_1, y_2$ .
2.  $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(y_1, y_2) dy_1 dy_2 = 1$ .

Para el caso univariado, las áreas bajo la densidad de probabilidad para un intervalo corresponden a probabilidades. De igual manera la función de probabilidad bivalente  $f(y_1, y_2)$  traza una superficie de densidad de probabilidad sobre el plano  $(y_1, y_2)$  como se muestra en la siguiente figura.



Los volúmenes bajo esta superficie representan probabilidades. Así,  $P(a_1 \leq Y_1 \leq a_2, b_1 \leq Y_2 \leq b_2)$  es el volumen sombreado que se ve en la figura anterior y a continuación.

$$\int_{b_1}^{b_2} \int_{a_1}^{a_2} f(y_1, y_2) dy_1 dy_2$$

Esos métodos vistos se pueden generalizar para una función de probabilidad (o función de densidad de probabilidad) para la intersección de  $n$  eventos ( $Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n$ ). La función de probabilidad conjunta correspondiente al caso discreto está dada por

$$p(y_1, y_2, \dots, y_n) = P(Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n)$$

En el caso continuo se tiene lo siguiente,

$$P(Y_1 \leq y_1, Y_2 \leq y_2, \dots, Y_n \leq y_n) = F(y_1, \dots, y_n) = \int_{-\infty}^{y_1} \int_{-\infty}^{y_2} \dots \int_{-\infty}^{y_n} f(t_1, t_2, \dots, t_n) dt_n \dots dt_1$$

para todo conjunto de número reales  $(y_1, y_2, \dots, y_n)$ . Por último la función de densidad conjunta de  $Y_1, \dots, Y_n$  está dada por  $f(y_1, \dots, y_n)$ .

## 5.3 Distribuciones de probabilidad marginal y condicional

Recuerde que los valores distintos tomados por una variable aleatoria discreta representan eventos mutuamente excluyentes. De manera análoga, para todos los distintos pares de valores  $y_1, y_2$ , los eventos bivariados  $(Y_1 = y_1, Y_2 = y_2)$ , representados por  $(y_1, y_2)$ , son eventos mutuamente excluyentes. De esto se deduce que el evento univariado  $(Y_1 = y_1)$  es la unión de eventos bivariados del tipo  $(Y_1 = y_1, Y_2 = y_2)$ , con la unión tomada para todos los posibles valores de  $y_2$ .

### Definición 5.4

- a Sean  $Y_1$  y  $Y_2$  variables aleatorias discretas conjuntas con función de probabilidad  $p(y_1, y_2)$ . Entonces las *funciones de probabilidad marginal* de  $Y_1$  y  $Y_2$ , respectivamente, están dadas por

$$p_1(y_1) = \sum_{\text{todos } y_2} p(y_1, y_2)$$

$$p_2(y_2) = \sum_{\text{todos } y_1} p(y_1, y_2)$$

- b Sean  $Y_1$  y  $Y_2$  variables aleatorias continuas conjuntas con función de densidad conjunta  $f(y_1, y_2)$ . Entonces las *funciones de densidad marginal* de  $Y_1$  y  $Y_2$ , respectivamente, están dadas por

$$f_1(y_1) = \int_{-\infty}^{\infty} f(y_1, y_2) dy_2$$

$$f_2(y_2) = \int_{-\infty}^{\infty} f(y_1, y_2) dy_1$$

Llevemos ahora nuestra atención a distribuciones condicionales, viendo primero al caso discreto.

### Definición 5.5

Si  $Y_1$  y  $Y_2$  son variables aleatorias discretas conjuntas con función de probabilidad conjunta  $p(y_1, y_2)$  y funciones de probabilidad marginal  $p_1(y_1)$  y  $p_2(y_2)$ , respectivamente, entonces la *función de probabilidad discreta condicional* de  $Y_1$  dada  $Y_2$  es

$$p(y_1|y_2) = P(Y_1 = y_1|Y_2 = y_2) = \frac{P(Y_1 = y_1, Y_2 = y_2)}{P(Y_2 = y_2)} = \frac{p(y_1, y_2)}{p_2(y_2)}$$

siempre que  $p_2(y_2) > 0$ .

En el caso continuo no se obtiene la función de probabilidad condicional de forma sencilla. Esto es porque si  $Y_1$  y  $Y_2$  son continuas,

$P(Y_1 = y_1|Y_2 = y_2)$  no se puede definir por que  $(Y_1 = y_1)$  y  $(Y_2 = y_2)$  son eventos con probabilidad cero.

### Definición 5.6

Si  $Y_1$  y  $Y_2$  son variables aleatorias continuas conjuntas con función de densidad conjunta  $f(y_1, y_2)$ , entonces la *función de distribución condicional* de  $Y_1$  dado que  $Y_2 = y_2$  es

$$F(y_1|y_2) = P(Y_1 \leq y_1|Y_2 = y_2)$$

Como se está tratando con una variable aleatoria continua entonces es necesario utilizar integrales. Entonces si se quiere encontrar  $F(y_1)$  no se puede sumar sobre todos los valores de  $Y_2$ . Pero se puede hacer algo análogo al multiplicarlo por  $f_2(y_2)$  para obtener

$$F(y_1) = \int_{-\infty}^{\infty} F(y_1|y_2) f_2(y_2) dy_2$$

De consideraciones previas se tiene

$$\begin{aligned} F(y_1) &= \int_{-\infty}^{y_1} f_1(t_1) dt_1 = \int_{-\infty}^{y_1} \left[ \int_{-\infty}^{\infty} f(t_1, y_2) dy_2 \right] dt_1 \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{y_1} f(t_1, y_2) dt_1 dy_2 \end{aligned}$$

De estas dos expresiones para  $F(y_1)$ , debemos tener

$$\begin{aligned} F(y_1|y_2) f_2(y_2) &= \int_{-\infty}^{y_1} f(t_1, y_2) dt_1 \\ F(y_1|y_2) &= \int_{-\infty}^{\infty} \frac{f(t_1, y_2)}{f_2(y_2)} dt_1 \end{aligned}$$

### Definición 5.7

Sean  $Y_1$  y  $Y_2$  variables aleatorias continuas conjuntas con densidad conjunta  $f(y_1, y_2)$  y densidades marginales  $f_1(y_1)$  y  $f_2(y_2)$ , respectivamente. Para cualquier  $y_2$  tal que  $f_2(y_2) > 0$ , la densidad condicional de  $Y_1$  dada  $Y_2 = y_2$  está dada por

$$f(y_1|y_2) = \frac{f(y_1, y_2)}{f_2(y_2)}$$

y para cualquier  $y_1$  tal que  $f_1(y_1) > 0$ , la densidad condicional de  $Y_2$  dada  $Y_1 = y_1$  está dada por

$$f(y_2|y_1) = \frac{f(y_1, y_2)}{f_1(y_1)}$$

## 5.4 Variables aleatorias independientes

Se ha estudiado la independencia de eventos en capítulos anteriores. Esto se puede extender a variables aleatorias.

### Definición 5.8

Sea  $Y_1$  que tiene una función de distribución  $F_1(y_1)$  y sea  $Y_2$  que tiene una función de distribución  $F_2(y_2)$ , y  $F(y_1, y_2)$  es la función de distribución conjunta de  $Y_1$  y  $Y_2$ . Entonces se dice que  $Y_1$  y  $Y_2$  son *independientes* si y sólo si

$$F(y_1, y_2) = F_1(y_1) F_2(y_2)$$

para todo par de números reales  $(y_1, y_2)$ . Si  $Y_1$  y  $Y_2$  no son independientes, se dice que son *dependientes*.

### Teorema 5.4

Si  $Y_1$  y  $Y_2$  son variables discretas con función de probabilidad conjunta  $p(y_1, y_2)$  y funciones de probabilidad marginal  $p_1(y_1)$  y  $p_2(y_2)$ , respectivamente, entonces  $Y_1$  y  $Y_2$  son independientes si y sólo si

$$p(y_1, y_2) = p_1(y_1) p_2(y_2)$$

para todos los pares de números reales  $(y_1, y_2)$ . Si  $Y_1$  y  $Y_2$  son variables aleatorias continuas con función de densidad conjunta  $f(y_1, y_2)$  y funciones de densidad marginal  $f_1(y_1)$  y  $f_2(y_2)$ , respectivamente, entonces  $Y_1$  y  $Y_2$  son independientes si y sólo si

$$f(y_1, y_2) = f_1(y_1) f_2(y_2)$$

para todos los pares de números reales  $(y_1, y_2)$ .

### Teorema 5.5

Sean  $Y_1$  y  $Y_2$  que tienen densidad conjunta  $f(y_1, y_2)$  que es positiva si y sólo si  $a \leq y_1 \leq b$  y  $c \leq y_2 \leq d$ , para constantes  $a, b, c$  y  $d$ ; y  $f(y_1, y_2) = 0$  en otro caso. Entonces  $Y_1$  y  $Y_2$  son variables aleatorias independientes si y sólo si

$$f(y_1, y_2) = g(y_1) h(y_2)$$

donde  $g(y_1)$  es una función no negativa de  $y_1$  solamente y  $h(y_2)$  es una función no negativa de  $y_2$  solamente.

El beneficio del Teorema 5.5 es que en realidad no necesitamos obtener las densidades marginales. De hecho, las funciones  $g(y_1)$  y  $h(y_2)$  no necesitan ser funciones de densidad. Finalmente la definición 5.8 se puede generalizar a  $n$  dimensiones. Suponga que se tiene  $n$  variables aleatorias  $Y_1, \dots, Y_n$ , donde  $Y_i$  tiene función de distribución  $F_i(y_i)$ , para  $i = 1, 2, \dots, n$ ; y que estas  $n$  variables aleatorias tengan función de distribución conjunta  $F(y_1, \dots, y_n)$ . Entonces  $Y_1, Y_2, \dots, Y_n$  son independientes si y sólo si

$$F(y_1, y_2, \dots, y_n) = F_1(y_1) \cdots F_n(y_n)$$

para todos los números reales  $y_1, y_2, \dots, y_n$ , son las formas equivalentes obvias para los casos discretos y continuos.

## 5.5 El valor esperado de una función de variables aleatorias

### Definición 5.9

Sea  $g(Y_1, Y_2, \dots, Y_k)$  una función de las variables aleatorias discretas,  $Y_1, Y_2, \dots, Y_k$ , que tienen función de probabilidad  $p(y_1, y_2, \dots, y_k)$ . Entonces el *valor esperado* de  $g(Y_1, Y_2, \dots, Y_k)$  es

$$E[g(Y_1, \dots, Y_k)] = \sum_{\text{toda } y_k} \cdots \sum_{\text{toda } y_1} g(y_1, \dots, y_k) p(y_1, \dots, y_k)$$

Si  $Y_1, Y_2, \dots, Y_k$  son variables aleatorias continuas con función de densidad conjunta  $f(y_1, y_2, \dots, y_k)$ , entonces

$$E[g(Y_1, \dots, Y_k)] = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(y_1, \dots, y_k) \times f(y_1, \dots, y_k) dy_1 \dots dy_k$$

Se puede demostrar que la Definición 5.9 es consistente con la definición 4.5, en la que se define el valor esperado de una variable aleatoria univariada de la siguiente manera. Considere dos variables aleatorias  $Y_1$  y  $Y_2$  con función de densidad  $f(y_1, y_2)$ . Deseamos hallar el valor esperado de  $g(Y_1, Y_2) = Y_1$ . De la definición anterior se tiene.

$$\begin{aligned} E(Y_1) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y_1 f(y_1, y_2) dy_2 dy_1 \\ &= \int_{-\infty}^{\infty} y_1 \left[ \int_{-\infty}^{\infty} f(y_1, y_2) dy_2 \right] dy_1 \end{aligned}$$

La cantidad dentro del paréntesis, por definición, es la función de densidad marginal para  $Y_1$ . Por lo tanto se puede obtener lo siguiente

$$E(Y_1) = \int_{-\infty}^{\infty} y_1 f_1(y_1) dy_1$$

## 5.6 Teoremas especiales

### Teorema 5.6

Sea  $c$  una constante. Entonces

$$E(c) = c$$

### Teorema 5.7

Sea  $g(Y_1, Y_2)$  una función de las variables aleatorias  $Y_1$  y  $Y_2$  y sea  $c$  una constante. Entonces

$$E[cg(Y_1, Y_2)] = cE[g(Y_1, Y_2)]$$

### Teorema 5.8

Sean  $Y_1$  y  $Y_2$  variables aleatorias y  $g_1(Y_1, Y_2)$ ,  $g_2(Y_1, Y_2)$ ,  $\dots$ ,  $g_k(Y_1, Y_2)$  funciones de  $Y_1$  y  $Y_2$ . Entonces

$$\begin{aligned} E[g_1(Y_1, Y_2) + g_2(Y_1, Y_2) \cdots + g_k(Y_1, Y_2)] \\ = E[g_1(Y_1, Y_2)] + E[g_2(Y_1, Y_2)] + \cdots + E[g_k(Y_1, Y_2)] \end{aligned}$$

### Teorema 5.9

Sean  $Y_1$  y  $Y_2$  variables aleatorias independientes y sean  $g(Y_1)$  y  $h(Y_2)$  funciones sólo de  $Y_1$  y  $Y_2$ , respectivamente. Entonces

$$E[g(Y_1)h(Y_2)] = E[g(Y_1)]E[h(Y_2)]$$

siempre que existan los valores esperados.

### Demostración

Daremos la demostración del resultado para el caso continuo. Denotemos con  $f(y_1, y_2)$  la densidad conjunta de  $Y_1$  y  $Y_2$ . El producto  $g(Y_1)h(Y_2)$  es una función de  $Y_1$  y  $Y_2$ . Entonces, por la Definición 5.9 y la suposición de que  $Y_1$  y  $Y_2$  son independientes,

$$\begin{aligned} E[g(Y_1)h(Y_2)] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(y_1)h(y_2)f(y_1, y_2) dy_2 dy_1 \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(y_1)h(y_2)f_1(y_1)f_2(y_2) dy_2 dy_1 \\ &= \int_{-\infty}^{\infty} g(y_1)f_1(y_1) \left[ \int_{-\infty}^{\infty} h(y_2)f_2(y_2) dy_2 \right] dy_1 \\ &= \int_{-\infty}^{\infty} g(y_1)f_1(y_1)E[h(Y_2)] dy_1 \\ &= E[h(Y_2)] \int_{-\infty}^{\infty} g(y_1)f_1(y_1) dy_1 \\ &= E[g(Y_1)]E[h(Y_2)] \end{aligned}$$

La demostración para el caso discreto sigue un modo análogo.

## 5.7 Covarianza de dos variables aleatorias

Intuitivamente consideramos la dependencia de dos variables aleatorias  $Y_1$  y  $Y_2$  como un procesos en el que una de las variables, por ejemplo  $Y_1$ , aumenta o disminuye cuando  $Y_2$  cambia. Concentraremos nuestra atención en dos medidas de dependencia: la covarianza entre dos variables aleatorias y su coeficiente de correlación.

### Definición 5.10

Si  $Y_1$  y  $Y_2$  son variables aleatorias con medias  $\mu_1$  y  $\mu_2$ , respectivamente, la *covarianza* de  $Y_1$  y  $Y_2$  es

$$Cov(Y_1, Y_2) = E[(Y_1 - \mu_1)(Y_2 - \mu_2)]$$

Cuanto mayor sea el valor absoluto de la covarianza de  $Y_1$  y  $Y_2$ , mayor será la dependencia lineal entre  $Y_1$  y  $Y_2$ . Los valores positivos indican que  $Y_1$  aumenta cuando  $Y_2$  aumenta; los valores negativos indican que  $Y_1$  disminuye cuando  $Y_2$  aumenta. Un valor de cero indica que no hay dependencia lineal entre  $Y_1$  y  $Y_2$ .

Desafortunadamente, es difícil utilizar la covarianza como medida absoluta de dependencia por que su valor depende de la escala de medición. Este problema se puede solucionar al estandarizar su valor y ocupar el *coeficiente de correlación*,  $\rho$ , definida como

$$\rho = \frac{Cov(Y_1, Y_2)}{\sigma_1 \sigma_2}$$

donde  $\sigma_1$  y  $\sigma_2$  son desviaciones estándar de  $Y_1$  y  $Y_2$ , respectivamente. Además el coeficiente de correlación  $\rho$  satisface la desigualdad  $-1 \leq \rho \leq 1$ . Entonces,  $\rho > 0$  indica que  $Y_1$  aumenta a medida que  $Y_2$  aumenta y  $\rho = +1$  implica correlación perfecta, con todos los puntos cayendo en una recta con pendiente positiva. Un valor de  $\rho = 0$  implica cero covarianza y que no hay correlación. Un coeficiente  $\rho < 0$  implica una disminución en  $Y_2$  cuando  $Y_1$  aumenta, y  $\rho = -1$  implica correlación perfecta cayendo sobre una recta con pendiente negativa.

### Teorema 5.10

Si  $Y_1$  y  $Y_2$  son variables aleatorias con medias  $\mu_1$  y  $\mu_2$ , respectivamente, entonces

$$\begin{aligned} Cov(Y_1, Y_2) &= E[(Y_1 - \mu_1)(Y_2 - \mu_2)] \\ &= E(Y_1 Y_2) - E(Y_1)E(Y_2) \end{aligned}$$

### Demostración

$$\begin{aligned} \text{Cov}(Y_1, Y_2) &= E[(Y_1 - \mu_1)(Y_2 - \mu_2)] \\ &= E(Y_1 Y_2 - \mu_1 Y_2 - \mu_2 Y_1 + \mu_1 \mu_2) \end{aligned}$$

Del Teorema 5.8, el valor esperado de una suma es igual a la suma de los valores esperados; y del Teorema 5.7, el valor esperado de una constante multiplicado por una función de variables aleatorias es la constante por el valor esperado. Entonces,

$$\text{Cov}(Y_1, Y_2) = E(Y_1 Y_2) - \mu_1 E(Y_2) - \mu_2 E(Y_1) + \mu_1 \mu_2$$

Como  $E(Y_1) = \mu_1$  y  $E(Y_2) = \mu_2$ , se deduce que

$$\begin{aligned} \text{Cov}(Y_1, Y_2) &= E(Y_1 Y_2) - E(Y_1)E(Y_2) \\ &= E(Y_1 Y_2) - \mu_1 \mu_2 \end{aligned}$$

### Teorema 5.11

Si  $Y_1$  y  $Y_2$  son variables aleatorias independientes, entonces

$$\text{Cov}(Y_1, Y_2) = 0$$

Así, las variables aleatorias independientes deben ser no correlacionadas.

### Demostración

El Teorema 5.10 establece que

$$\text{Cov}(Y_1, Y_2) = E(Y_1 Y_2) - \mu_1 \mu_2$$

Como  $Y_1$  y  $Y_2$  son independientes, el Teorema 5.9 implica que

$$E(Y_1 Y_2) = E(Y_1)E(Y_2) = \mu_1 \mu_2$$

y el resultado deseado se deduce de inmediato.

## 5.8 Valor esperado y varianza de funciones lineales de variables aleatorias

Si  $a_1, a_2, \dots, a_n$  son constantes, será necesario calcular el valor esperado y varianza de una función lineal de las variables aleatorias  $Y_1, Y_2, \dots, Y_n$ . Esta se puede definir de la siguiente manera

$$U_1 = a_1 Y_1 + a_2 Y_2 + a_3 Y_3 + \dots + a_n Y_n = \sum_{i=1}^n a_i Y_i$$

### Teorema 5.12

Sean  $Y_1, Y_2, \dots, Y_n$  y  $X_1, X_2, \dots, X_m$  variables aleatorias con  $E(Y_i) = \mu_i$  y  $E(X_i) = \xi_i$ . Defina

$$U_1 = \sum_{i=1}^n a_i Y_i \quad U_2 = \sum_{j=1}^m b_j X_j$$

para las constantes  $a_1, a_2, \dots, a_n$  y  $b_1, b_2, \dots, b_m$ . Entonces se cumple lo siguiente:

**a**  $E(U_1) = \sum_{i=1}^n a_i \mu_i$ .

**b**

$$V(U_1) = \sum_{i=1}^n a_i^2 V(Y_i) + 2 \sum_{1 \leq i < j \leq n} a_i a_j \text{Cov}(Y_i, Y_j)$$

donde la doble suma es para todos los pares  $(i, j)$  con  $i < j$ .

**c**  $\text{Cov}(U_1, U_2) = \sum_{i=1}^n \sum_{j=1}^m a_i b_j \text{Cov}(Y_i, X_j)$

### Demostración

El teorema consta de tres partes, de las cuales (a) viene directamente de los Teoremas 5.7 y 5.8. Para demostrar (b) recurrimos a la definición de varianza y escribimos

$$\begin{aligned} V(U_1) &= E[U_1 - E(U_1)]^2 = E \left[ \sum_{i=1}^n a_i Y_i - \sum_{i=1}^n a_i \mu_i \right]^2 \\ &= E \left[ \sum_{i=1}^n a_i (Y_i - \mu_i) \right]^2 \\ &= E \left[ \sum_{i=1}^n a_i^2 (Y_i - \mu_i)^2 + \sum_{i=1}^n \sum_{\substack{j=1 \\ i \neq j}}^n a_i a_j (Y_i - \mu_i)(Y_j - \mu_j) \right] \\ &= \sum_{i=1}^n a_i^2 E(Y_i - \mu_i)^2 + \sum_{i=1}^n \sum_{\substack{j=1 \\ i \neq j}}^n a_i a_j E[(Y_i - \mu_i)(Y_j - \mu_j)] \end{aligned}$$

Por las definiciones de varianza y covarianza tenemos

$$V(U_1) = \sum_{i=1}^n a_i^2 V(Y_i) + \sum_{i=1}^n \sum_{\substack{j=1 \\ i \neq j}}^n a_i a_j \text{Cov}(Y_i, Y_j)$$

Como  $\text{Cov}(Y_i, Y_j) = \text{Cov}(Y_j, Y_i)$ , podemos escribir

### Demostración

$$V(U_1) = \sum_{i=1}^n a_i^2 V(Y_i) + 2 \sum_{1 \leq i < j \leq n} a_i a_j \text{Cov}(Y_i, Y_j)$$

Se pueden usar pasos similares para obtener (c). Tenemos

$$\begin{aligned} \text{Cov}(U_1, U_2) &= E\{[U_1 - E(U_1)][U_2 - E(U_2)]\} \\ &= E \left[ \left( \sum_{i=1}^n a_i Y_i - \sum_{i=1}^n a_i \mu_i \right) \left( \sum_{j=1}^m b_j X_j - \sum_{j=1}^m b_j \xi_j \right) \right] \\ &= E \left\{ \left[ \sum_{i=1}^n a_i (Y_i - \mu_i) \right] \left[ \sum_{j=1}^m b_j (X_j - \xi_j) \right] \right\} \\ &= E \left[ \sum_{i=1}^n \sum_{j=1}^m a_i b_j (Y_i - \mu_i)(X_j - \xi_j) \right] \\ &= \sum_{i=1}^n \sum_{j=1}^m a_i b_j E[(Y_i - \mu_i)(X_j - \xi_j)] \\ &= \sum_{i=1}^n \sum_{j=1}^m a_i b_j \text{Cov}(Y_i, X_j) \end{aligned}$$

Al observar que  $\text{Cov}(Y_i, Y_i) = V(Y_i)$ , podemos ver que (b) es un caso especial de (c).

## 5.9 Distribución de probabilidad multinomial

Recuerde del Capítulo 3 que una variable aleatoria binomial resulta de un experimento que consiste en  $n$  intentos con dos posibles resultados por intento. Un experimento multinomial es una generalización del experimento binomial.

### Definición 5.11

Un *experimento multinomial* posee las siguientes propiedades:

1. El experimento consta de  $n$  intentos idénticos.
2. El resultado de cada intento cae en una de  $k$  clases o celdas.
3. La probabilidad de que el resultado de un solo intento caiga en la celda  $i$  es  $p_i$ .  $i = 1, 2, \dots, k$  y sigue siendo el mismo de un intento a otro. Observe que  $p_1 + p_2 + p_3 + \dots + p_k = 1$ .
4. Los intentos son independientes.
5. Las variables aleatorias de interés son  $Y_1, Y_2, \dots, Y_k$ , donde  $Y_i$  es igual al número de intentos para los cuales el resultado cae en la celda  $i$ . Observe que  $Y_1 + Y_2 + Y_3 + \dots + Y_k = n$ .

### Definición 5.12

Suponga que  $p_1, p_2, \dots, p_k$  son tales que  $\sum_{i=1}^k p_i = 1$ , y  $p_i > 0$  para  $i = 1, 2, \dots, k$ . Se dice que las variables aleatorias  $Y_1, Y_2, \dots, Y_k$  tienen una *distribución multinomial* para parámetro  $n$  y  $p_1, p_2, \dots, p_k$  si la función de probabilidad conjunta de  $Y_1, Y_2, \dots, Y_k$  está dada por

$$p(y_1, y_2, \dots, y_k) = \frac{n!}{y_1! y_2! \dots y_k!} p_1^{y_1} p_2^{y_2} \dots p_k^{y_k}$$

donde, para cada  $i = 0, 1, 2, \dots, n$  y  $\sum_{i=1}^k y_i = n$ .

Muchos experimentos en los que aparece una clasificación son multinomiales. Observe que el experimento binomial es un caso especial del experimento multinomial (cuando hay  $k = 2$  clases).

### Teorema 5.13

Si  $Y_1, Y_2, \dots, Y_k$  tienen una distribución binomial con parámetros  $n$  y  $p_1, p_2, \dots, p_k$ , entonces

1.  $E(Y_i) = np_i$ ,  $V(Y_i) = np_i q_i$ .
2.  $Cov(Y_s, Y_t) = -np_s p_t$ , si  $s \neq t$ .

### Demostración

La distribución marginal de  $Y_i$  se puede usar para obtener la media y varianza. Recuerde que  $Y_i$  puede ser interpretada como el número de intento que caen en la celda  $i$ . Imagine todas las celdas, excluyendo la  $i$ , combinadas en una sola celda grande. Entonces cada intento resultará en la celda  $i$  o en una celda que no sea la  $i$ , con probabilidades  $p_i$  y  $1 - p_i$ , respectivamente. Entonces  $Y_i$  posee una distribución de probabilidad marginal binomial. EN consecuencia,

$$E(Y_i) = np_i \quad V(Y_i) = np_i q_i$$

donde  $q_i = 1 - p_i$ . Los mismos resultados se pueden obtener al establecer los valores esperados y evaluar. Por ejemplo,

$$E(Y_1) = \sum_{y_1} \sum_{y_2} \dots \sum_{y_k} y_1 \frac{n!}{y_1! y_2! \dots y_k!} p_1^{y_1} p_2^{y_2} \dots p_k^{y_k}$$

Como ya hemos deducido el valor esperado y la varianza de  $Y_i$ , dejamos la sumatoria de este valor esperado para el lector interesado.

### Demostración

La demostración de la parte 2 usa el Teorema 5.12. Considere el experimento multinomial como una sucesión de  $n$  intento independientes y defina, para  $s \neq t$ ,

$$U_i = \begin{cases} 1, & \text{si el intento } i \text{ resulta en clase } s, \\ 0, & \text{de otro modo} \end{cases}$$

y

$$W_i = \begin{cases} 1, & \text{si el intento } i \text{ resulta en clase } t, \\ 0, & \text{de otro modo} \end{cases}$$

Entonces

$$Y_s = \sum_{i=1}^n U_i \quad Y_t = \sum_{j=1}^n W_j$$

(Como  $U_i = 1$  o 0 dependiendo de si el  $i$ -ésimo intento resultó en clase  $s$ ,  $Y_s$  es simplemente la suma de una serie de número 0 y 1. Ocurre un 1 en la suma cada vez que observamos un artículo de la clase  $s$  y 0 cada vez que observamos cualquier otra clase. Entonces,  $Y_s$  es simplemente el número de veces que se observe la clase  $s$ . Una interpretación similar se aplica a  $Y_t$ .)

Observe que  $U_i$  y  $W_i$  no pueden ser iguales a 1 (el  $i$ -ésimo artículo no puede estar simultáneamente en las clases  $s$  y  $t$ ). Entonces el producto  $U_i W_i$  siempre es igual a cero y  $E(U_i W_i) = 0$ . Los siguientes resultados nos permiten evaluar  $Cov(Y_s, Y_t)$ :

$$E(U_i) = p_s$$

$$E(W_j) = p_t$$

$$Cov(U_i, W_j) = 0$$

si  $i \neq j$  porque los intentos son independientes

$$Cov(U_i, W_i) = E(U_i W_i) - E(U_i)E(W_i) = 0 - p_s p_t$$

Del Teorema 5.12 tenemos entonces

$$\begin{aligned} Cov(Y_s, Y_t) &= \sum_{i=1}^n \sum_{j=1}^n Cov(U_i, W_j) \\ &= \sum_{i=1}^n Cov(U_i, W_i) + \sum_{i \neq j} Cov(U_i, W_j) \\ &= \sum_{i=1}^n (-p_s p_t) + \sum_{i \neq j} 0 \\ &= -np_s p_t \end{aligned}$$

La covarianza es negativa, lo que ya se esperaba, porque un gran número de resultados en la celda  $s$  forzaría al número de la celda  $t$  a ser pequeño.

## 5.10 Distribución normal bivalente (opcional)

La distribución normal multivariante es muy importante en la teoría moderna de estadística. En general, la función de densidad normal multivariante se define para  $k$  variables aleatorias continuas,  $Y_1, Y_2, \dots, Y_k$ . Debido a su complejidad, presentaremos sólo la función de densidad bivalente ( $k = 2$ ):

$$f(y_1, y_2) = \frac{e^{-Q/2}}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \quad -\infty < y_1 < \infty, -\infty < y_2 < \infty$$

donde

$$Q = \frac{1}{1-\rho^2} \left[ \frac{(y_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(y_1 - \mu_1)(y_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(y_2 - \mu_2)^2}{\sigma_2^2} \right]$$

La función de densidad normal bivalente es una función de cinco parámetros:  $\mu_1, \mu_2, \sigma_1^2, \sigma_2^2$  y  $\rho$ .

## 5.11 Valores esperados condicionales

### Definición 5.13

Si  $Y_1$  y  $Y_2$  son dos variables aleatorias cualesquiera, el *valor esperado condicional* de  $g(Y_1)$ , dado que  $Y_2 = y_2$ , se define que es

$$E(g(Y_1)|Y_2 = y_2) = \int_{-\infty}^{\infty} g(y_1)f(y_1|y_2)dy_1$$

si  $Y_1$  y  $Y_2$  son continuas conjuntamente y

$$E(g(Y_1)|Y_2 = y_2) = \sum_{\text{toda } y_1} g(y_1)p(y_1|y_2)$$

si  $Y_1$  y  $Y_2$  son discretas conjuntamente.

En general, el valor esperado condicional de  $Y_1$  dada  $Y_2 = y_2$  es una función de  $y_2$ . Si ahora hacemos variar  $Y_2$  en todos sus posibles valores, podemos considerar el valor esperado condicional  $E(Y_1|Y_2)$  como una función de la variable aleatoria  $Y_2$ . Como  $E(Y_1|Y_2)$  es una función de la variable aleatoria  $Y_2$ , también es una variable aleatoria; y como tal, tiene media y varianza.

### Teorema 5.14

Si  $Y_1$  y  $Y_2$  son dos variables aleatorias, entonces

$$E(Y_1) = E[E(Y_1|Y_2)]$$

donde en el lado derecho de la ecuación el valor esperado interior es con respecto a la distribución condicional de  $Y_1$  dada  $Y_2$  y el valor esperado exterior es con respecto a la distribución de  $Y_2$ .

### Demostración

Suponga que  $Y_1$  y  $Y_2$  son continuas conjuntamente con función de densidad conjunta  $f(y_1, y_2)$  y densidades marginales  $f_1(y_1)$  y  $f_2(y_2)$ , respectivamente. Entonces

$$\begin{aligned} E(Y_1) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y_1 f(y_1, y_2) dy_1 dy_2 \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y_1 f(y_1|y_2) f_2(y_2) dy_1 dy_2 \\ &= \int_{-\infty}^{\infty} \left[ \int_{-\infty}^{\infty} y_1 f(y_1|y_2) dy_1 \right] f_2(y_2) dy_2 \\ &= \int_{-\infty}^{\infty} E(Y_1|Y_2 = y_2) f_2(y_2) dy_2 \\ &= E[E(Y_1|Y_2)] \end{aligned}$$

La demostración es semejante para el caso discreto.

La varianza condicional de  $Y_1$  dada  $Y_2 = y_2$  está definida por analogía con una varianza ordinaria, de nuevo utilizando la densidad condicional o función de probabilidad de  $Y_1$  dada  $Y_2 = y_2$  en lugar de la densidad ordinaria o función de probabilidad  $Y_1$ . Esto es,

$$V(Y_1|Y_2 = y_2) = E(Y_1^2|Y_2 = y_2) - [E(Y_1|Y_2 = y_2)]^2$$

Como en el caso de la media condicional, la varianza condicional es una función de  $y_2$ . Si dejamos que  $Y_2$  tome todos sus valores posibles, podemos definir  $V(Y_1|Y_2)$  como una variable aleatoria que es una función de  $Y_2$ . Específicamente, si  $g(y_2) = V(Y_1|Y_2 = y_2)$  es una función particular del valor observado  $y_2$ , entonces  $g(Y_2) = V(Y_1|Y_2)$  es la *misma función* de la variable aleatorias,  $Y_2$ .

### Teorema 5.15

Si  $Y_1$  y  $Y_2$  representan variables aleatorias, entonces

$$V(Y_1) = E[V(Y_1|Y_2)] + V[E(Y_1|Y_2)]$$

### Demostración

Como se indicó antes,  $V(Y_1|Y_2)$  está dada por

$$V(Y_1|Y_2) = E(Y_1^2|Y_2) - [E(Y_1|Y_2)]^2$$

y

$$E[V(Y_1|Y_2)] = E[E(Y_1^2|Y_2)] - E\{[E(Y_1|Y_2)]^2\}$$

Por definición,

$$V[E(Y_1|Y_2)] = E\{[E(Y_1|Y_2)]^2\} - \{E[E(Y_1|Y_2)]\}^2$$

La varianza de  $Y_1$  es

$$\begin{aligned} V(Y_1) &= E[Y_1^2] - [E(Y_1)]^2 \\ &= E\{E[Y_1^2|Y_2]\} - \{E[E(Y_1|Y_2)]\}^2 \\ &= E\{E[Y_1^2|Y_2]\} - E\{[E(Y_1|Y_2)]^2\} + E\{[E(Y_1|Y_2)]^2\} \\ &\quad - \{E[E(Y_1|Y_2)]\}^2 \\ &= E[V(Y_1|Y_2)] + V[E(Y_1|Y_2)] \end{aligned}$$